



信息学院 _ _ _ 系 _ 2023 _ 年级 _ _ _ 专业 _ _ _

学年学期：2025-2026(2) _ 主考教师：毛波 A 卷 (√) B 卷 ()

一、单项选择题（本题共 20 分，每小题 1 分）

- 1、在大数据计算中，GPU 之所以能显著加速特定任务，主要是因为其架构特点是？
 - A. 拥有超大容量的缓存
 - B. 拥有大量的核心，适合大规模并行计算
 - C. 拥有极高的单核主频
 - D. 支持复杂的逻辑控制指令
- 2、在云计算的服务模式中，为用户提供虚拟化的计算资源（如虚拟机）的服务模式是？
 - A. SaaS（软件即服务）
 - B. PaaS（平台即服务）
 - C. IaaS（基础设施即服务）
 - D. DaaS（数据即服务）
- 3、虚拟化技术中，直接运行在物理硬件之上，用于管理虚拟机和分配硬件资源的软件层被称为？
 - A. 宿主型虚拟化
 - B. Hypervisor（虚拟机监视器）
 - C. 容器引擎
 - D. 操作系统内核
- 4、Google 文件系统（GFS）架构中，负责管理文件系统元数据（如文件名、目录结构、文件块映射信息）的服务器是？
 - A. ChunkServer
 - B. Master
 - C. Client
 - D. NameNode
- 5、在 Hadoop 生态系统中，HDFS 默认的块（Block）大小通常是？
 - A. 32MB
 - B. 64MB
 - C. 128MB
 - D. 256MB
- 6、关于 Spark 与 Hadoop 的对比，以下说法正确的是？
 - A. Spark 基于磁盘计算，Hadoop 基于内存计算
 - B. Spark 比 Hadoop 的批处理速度更快
 - C. Spark 不支持实时数据处理
 - D. Hadoop 不支持分布式存储
- 7、以下哪种数据库属于 NoSQL 类型？
 - A. MySQL
 - B. MongoDB
 - C. Oracle
 - D. PostgreSQL
- 8、性能介于非易失性内存和磁盘之间的存储设备是_____。
 - A. 寄存器
 - B. RAM
 - C. 闪存
 - D. 光盘
- 9、5 个磁盘组成的 RAID5 最多可以容忍_____个磁盘故障而不丢失数据。

A. 1 B. 2 C. 3 D. 4

10、GPU 适用于处理_____类型的处理任务。

A. SISD B. SIMD C. MISD D. MIMD

11、衡量数据量大小的单位中，介于 TB 和 EB 之间的单位是_____。

A. PB B. MB C. ZB D. YB

12、实时流处理技术 Spark 是根据_____来对数据进行分块的。

A. 时间 B. 类型 C. 重要性 D. 存储位置

13、云计算的三大主要服务模型不包括下面哪一项_____。

A. 基础架构即服务 (IaaS) B. 平台即服务 (PaaS)

C. 软件即服务 (SaaS) D. 存储即服务 (SaaS)

14、下列哪一项不属于大数据处理开源项目 Hadoop 中的子项目_____。

A. HBase B. Chubby C. ZooKeeper D. Spark

15、Hadoop 中是通过_____技术来提高存储数据的可靠性。

A. 双备份 B. 复制 C. 日志 D. 校验码

16、重复数据删除技术主要是利用数据内容的_____比对来检测冗余数据。

A. Bloom Filter B. Hash C. Bit Map D. Encryption

17、下列_____不是虚拟机。

A. KVM B. VMware C. Xen D. GFS

18、以下哪项是分布式协调服务工具？

A. Apache Kafka B. Apache ZooKeeper

C. Apache Flink D. Apache Storm

19、下列哪项技术主要用于减少备份窗口和存储空间，通过消除冗余数据来实现？

A. 数据加密 B. 数据压缩与重复数据删除

C. 数据分片 D. 数据脱敏

20、固态硬盘 (SSD) 在频繁写入时面临的主要寿命问题是？

A. 磁头磨损 B. 碟片划伤

C. 写入放大与擦写次数限制 D. 旋转马达故障

二、填空题 (本题 20 分)

1、在 Hadoop 的分布式文件系统 (HDFS) 中，采用了典型的主从 (Master-Slave) 架构。其中，负责管理文件系统命名空间、处理客户端元数据请求的核心主节点被称为 _____；负责实际存储数据块 (Block) 并执行读写操作的从节点被称为 _____。(共 4 分)

2、假设每个磁盘容量为 1TB，根据存储虚拟化和 RAID 相关知识填写下表 (共 8 分)。

级别	盘个数	容量 (TB)	存储效率
RAID 0	8		

RAID 1	8		
RAID 5	8		
RAID 6	8		

3、NoSQL 数据库为了应对海量数据和多样化的数据模型，主要被划分为四大类。其中，Redis 是典型的 _____ 存储数据库，以极高的读写性能著称；MongoDB 属于 _____ 存储数据库，其数据格式类似于 JSON；HBase 是基于列族的 _____ 存储数据库，适合海量数据的随机实时读写；而 Neo4j 则是专门用于处理复杂关系网络的 _____ 存储数据库。（共 4 分）

4、在云计算和大数据处理的数据中心环境中，_____（填写英文缩写）作为虚拟机监视器，是运行在物理硬件与虚拟机之间的核心软件层，负责资源的分配与隔离。在物理存储介质方面，固态硬盘（SSD）的核心存储单元是 _____（填写英文缩写）闪存颗粒。相比于传统机械硬盘（HDD），SSD 没有机械寻道延迟，因此在处理大数据场景下的 _____（选填“顺序”或“随机”）读写任务时性能提升尤为显著。但 SSD 也面临写入寿命的限制，因此在数据中心常采用 _____ 技术来均衡各个存储单元的磨损程度。（共 4 分）

三、简答题（本题 40 分）

- 1、请简述大数据的“4V”特征，并简要说明其含义（8 分）。
- 2、在 Hadoop 生态系统中，HDFS（Hadoop 分布式文件系统）采用了主从架构，请画出架构图，并简述 NameNode 和 DataNode 各自的主要职责是什么？（6 分）。
- 3、在云计算与大数据处理中，虚拟化技术至关重要。请简述全虚拟化（Full Virtualization）与容器技术（如 Docker）在架构和性能上的主要区别。（8 分）。
- 4、随着硬件技术的发展，固态硬盘（SSD）在大数据存储中扮演着越来越重要的角色。请简述 SSD 相比传统机械硬盘（HDD）在大数据处理场景下的主要优势，以及它面临的一个主要寿命挑战是什么？（6 分）
- 5、从处理类型、延迟和数据分块角度分析 Hadoop 和 Spark 的区别（6 分）
- 6、谈谈 CPU、GPU、和 DPU 的主要异同，并说明异构计算出现的主要原因（6 分）

四、系统设计与分析题（本题 20 分）

企业级实时电商用户行为分析平台

【背景描述】某大型电商平台计划构建一套全新的“实时用户行为分析系统”。该系统需要处理海量且高并发的用户点击流、浏览日志和交易数据。业务部门提出了以下核心需求：

1、高吞吐与实时性：系统需具备应对突发流量（如“双十一”秒杀活动）的能力，能够实时采集并处理每秒数十万条的用户行为日志，延迟需控制在秒级。

2、海量存储与高效查询：需要存储近一年的历史行为数据（PB 级别），并支持运营人员通过类 SQL 语句进行灵活的多维分析（如查询某类商品在过去一个月的点击转化率）。

3、个性化推荐支持：需要为前端的推荐系统提供毫秒级的用户画像查询接口（如根据用户 ID 快速获取其最近浏览的 10 个商品类别）。

4、成本与性能平衡：在满足性能的前提下，需合理利用数据中心的硬件资源（包括新型存储设备）以控制成本。

【问题】请结合《大数据处理》课程所学的知识，回答以下问题：

1、（架构设计） 请设计该系统的整体逻辑架构。要求明确画出或描述数据采集层、数据处理层、数据存储层和应用层所采用的核心技术组件（需涵盖 Hadoop 生态、NoSQL 数据库、消息队列等），并简要说明数据在各层之间的流转过程（10 分）。

2、（技术选型与分析） 针对背景中的需求 2 和需求 3，请分别说明你会选择哪种具体的存储技术（例如：HDFS、HBase、Redis、SSD 等），并结合该技术的特点（如读写模式、数据结构、底层介质等）详细阐述选择的理由（5 分）。

3、（资源优化） 面对“双十一”期间的突发流量，除了软件层面的优化，请从云计算/虚拟化和数据中心硬件的角度，提出两条具体的资源调度或硬件配置策略，以保证系统不被爆发的日志数据压垮（5 分）。